

การพัฒนาแบบจำลองการเรียนรู้เชิงลึกแบบอนุกรมเวลา
เพื่อทำนายภาวะช็อกในแผนกผู้ป่วยวิกฤต
โรงพยาบาลศรีนครินทร์ จังหวัดขอนแก่น
Developing a Time Series Deep Learning Model to Predict
Shock in ICU Patients at Srinagarind Hospital,
Khon Kaen

นายธนบดี ภูชมศรี, นายพุทธิพงศ์ ยางนอก
อาจารย์ที่ปรึกษา : อ.ดร.พิชญา วิรัชโชติเสถียร
สาขาวิชาสถิติ คณะวิทยาศาสตร์ มหาวิทยาลัยขอนแก่น

บทคัดย่อ

ภาวะช็อกเป็นภาวะที่พบบ่อยในผู้ป่วยที่เข้ารับการรักษาในห้องผู้ป่วยวิกฤต (Intensive Care Unit; ICU) และมีความสัมพันธ์กับอัตราการเสียชีวิตที่สูงทั่วโลก จากการศึกษาพบว่าภาวะช็อกเกิดขึ้นในผู้ป่วยที่เข้ารับการรักษาใน ICU ถึงร้อยละ 29.5 และมีอัตราการเสียชีวิตในโรงพยาบาลสูงถึงร้อยละ 35.3 เมื่อเทียบกับผู้ป่วยที่ไม่มีภาวะช็อกซึ่งมีอัตราการเสียชีวิตร้อยละ 16.7 การทำนายภาวะช็อกล่วงหน้าจึงมีความสำคัญอย่างยิ่งในการลดอัตราการเสียชีวิตและภาวะแทรกซ้อน งานวิจัยนี้ทำการศึกษาเกี่ยวกับผู้ป่วยใน ICU ที่โรงพยาบาลศรีนครินทร์ จังหวัดขอนแก่น โดยใช้ข้อมูลทุติยภูมิจากระบบ Smart-ICU ซึ่งรวมถึงข้อมูลทางประชากรศาสตร์ ประวัติการรักษา ผลการตรวจทางห้องปฏิบัติการ สัญญาณชีพ และสมดุลงานในร่างกาย โดยศึกษาในผู้ป่วยที่มีอายุ 18 ปีขึ้นไป ที่เข้ารับการรักษาในวันที่ 15 ตุลาคม 2565 ถึง 3 กุมภาพันธ์ 2568 และต้องมีการเข้ารับการรักษาใน ICU อย่างน้อย 24 ชั่วโมง โดยภาวะช็อกจะถูกกำหนดจากเกณฑ์ อย่างใดอย่างหนึ่งดังนี้ ความดันโลหิตเฉลี่ย < 65 มิลลิเมตรปรอท ความดันโลหิตซิสโตลิก < 90 มิลลิเมตรปรอท หรือดัชนีช็อกของความดันโลหิต > 2 โดยในการทำนายภาวะช็อก ผู้วิจัยได้ใช้เทคนิคการเรียนรู้เชิงลึกแบบอนุกรมเวลา (Time-Series Deep Learning) ที่มีความซับซ้อนสูง เช่น โครงข่ายประสาทแบบคอนโวลูชัน (Convolutional Neural Networks หรือ CNN) โครงข่ายหน่วยความจำระยะสั้นและยาว (Long Short-Term Memory Networks หรือ LSTM Networks) และ แบบจำลองทรานส์ฟอร์มเมอร์ (Transformer models) ผลการศึกษาพบว่าแบบจำลองแบบผสม CNN+LSTM ให้ผลลัพธ์ที่ดีที่สุด โดยมีค่า AUC-ROC 0.89 และ AUC-PR 0.91 ซึ่งดีกว่าแบบจำลองเดี่ยวแบบอื่น ๆ แสดงให้เห็นถึงความสามารถของแบบจำลองแบบผสมในการวิเคราะห์ทั้งลักษณะเชิงเวลา

และเชิงพื้นที่ ทำให้การทำนายแม่นยำขึ้นอย่างมีนัยสำคัญ ซึ่งสามารถช่วยให้แพทย์วางแผนการรักษาได้อย่างเหมาะสมและทันเวลา

คำสำคัญ : ภาวะช็อก, แผนกผู้ป่วยวิกฤต (ICU), ข้อมูลอนุกรมเวลา, การเรียนรู้เชิงลึก, โครงข่ายประสาทแบบคอนโวลูชัน (CNN), โครงข่ายหน่วยความจำระยะสั้นและยาว (LSTM)

Abstract

Shock is a common condition among patients admitted to the Intensive Care Unit (ICU) and is associated with high mortality rates worldwide. Studies have found that shock occurs in 29.5% of ICU patients, with a hospital mortality rate of 35.3% compared to 16.7% in patients without shock. Early prediction of shock is therefore crucial for reducing mortality and complications. This study investigates ICU patients at Srinagarind Hospital, Khon Kaen, Thailand, using secondary data from the Smart-ICU system. The dataset includes patient demographics, medical histories, laboratory results, vital signs, and fluid balance. The study focuses on patients aged 18 years or older, admitted between October 15, 2022, and February 3, 2025, with a minimum ICU stay of 24 hours. Shock was defined by at least one of the following criteria: mean arterial pressure < 65 mmHg, systolic blood pressure < 90 mmHg, or a diastolic shock index > 2 . To predict shock, advanced time-series deep learning techniques were utilized, including Convolutional Neural Networks (CNN), Long Short-Term Memory (LSTM) networks, and Transformer models. The CNN+LSTM hybrid model achieved the best performance, with an AUC-ROC of 0.89 and an AUC-PR of 0.91, outperforming standalone models. This performance underscores the hybrid model's ability to integrate temporal and spatial features, significantly enhancing predictive accuracy. This study demonstrates the potential of using the CNN+LSTM hybrid model for predicting shock among ICU patients, which can be further developed into a real-time shock prediction system.

Keywords : Shock, Intensive Care Unit (ICU), Time-series data, Deep learning, Convolutional Neural Networks (CNN), Long Short-Term Memory (LSTM) networks

1. บทนำ

ปัจจุบันภาวะช็อก (Shock) เป็นหนึ่งในภาวะฉุกเฉินที่พบบ่อยในผู้ป่วยที่เข้ารับการรักษาในแผนกผู้ป่วยวิกฤต (Intensive Care Unit; ICU) และมีความสัมพันธ์กับอัตราการเสียชีวิตที่สูงทั่วโลก การศึกษาระดับนานาชาติพบว่าภาวะช็อกเกิดขึ้นในผู้ป่วย ICU ถึงร้อยละ 29.5 โดยมีอัตราการเสียชีวิตสูงถึงร้อยละ 35.3 เมื่อเทียบกับผู้ป่วยที่ไม่มีภาวะช็อกซึ่งมีอัตราการเสียชีวิตร้อยละ 16.7 [9] ภาวะช็อกมีลักษณะร่วมคือการลดลงของการไหลเวียนโลหิตที่ส่งผลต่อการทำงานของอวัยวะสำคัญและนำไปสู่ภาวะขาดออกซิเจนในระดับเซลล์ โดยผู้ป่วยอาจมีความดันโลหิตต่ำ ระดับความดันโลหิตเฉลี่ยต่ำกว่า 65 มิลลิเมตรปรอท หรือมีดัชนีช็อกที่สูงเกินปกติ [11] ปัจจัยสำคัญที่ทำให้อัตราการเสียชีวิตยังคงสูงคือการวินิจฉัยและการรักษาที่ล่าช้า โดยทุกๆ ชั่วโมงที่ล่าช้าในการให้ยาปฏิชีวนะในช่วง 6 ชั่วโมงแรกจะเพิ่มความเสี่ยงต่อการเสียชีวิตถึง 7.6% ต่อชั่วโมง [7] หากมีการทำนายและจัดการภาวะช็อกล่วงหน้าจะช่วยลดอัตราการเสียชีวิตและภาวะแทรกซ้อนได้

งานวิจัยในปัจจุบันมีการนำเทคนิคการเรียนรู้เชิงลึกแบบอนุกรมเวลา (Time Series Deep Learning) มาใช้เนื่องจากความรุนแรงของอาการนั้นเป็นเรื่องละเอียดอ่อนต่อเวลา [2] เช่น เทคนิคหน่วยความจำระยะสั้นระยะยาว (LSTM) และเทคนิคทรานส์ฟอร์มเมอร์ (Transformer) ที่สามารถเรียนรู้ความสัมพันธ์ที่ซับซ้อนในข้อมูลได้เป็นอย่างดี [10] ผู้วิจัยเห็นความสำคัญของเทคนิคเหล่านี้ที่จะช่วยในการทำนายการเกิดภาวะช็อกอย่างมีประสิทธิภาพและทันทั่วทั้ง

งานวิจัยนี้จึงนำเทคนิคการเรียนรู้เชิงลึกแบบอนุกรมเวลาไปประยุกต์ใช้กับข้อมูลผู้ป่วยที่มีภาวะช็อกในโรงพยาบาลศรีนครินทร์ จังหวัดขอนแก่น โดยสร้างและเปรียบเทียบประสิทธิภาพของแบบจำลองสำหรับการทำนายภาวะช็อกของผู้ป่วยใน ICU เพื่อหาแบบจำลองที่มีประสิทธิภาพดีที่สุด สำหรับการนำไปกำหนดแนวทางในการรักษาป้องกัน และช่วยให้แพทย์สามารถวางแผนการรักษาได้อย่างเหมาะสมและทันเวลา

2. ทบทวนวรรณกรรม และงานวิจัยที่เกี่ยวข้อง

2.1 ภาวะช็อก

ภาวะช็อกเป็นภาวะทางการแพทย์ที่เกิดจากการไหลเวียนเลือดผิดปกติ ส่งผลให้เลือดไปเลี้ยงเนื้อเยื่อและอวัยวะลดลงอย่างรุนแรง นำไปสู่ภาวะขาดออกซิเจนในระดับเซลล์ (cellular hypoxia) และการล้มเหลวของอวัยวะหลายระบบ ภาวะช็อกแบ่งได้เป็น ภาวะช็อกจากการสูญเสียเลือดหรือสารน้ำ (Hypovolemic shock), ภาวะช็อกจากการทำงานของหัวใจผิดปกติ (Cardiogenic shock), ภาวะช็อกจากการอุดตันทางเดินเลือด (Obstructive shock) และภาวะช็อกจากการกระจายตัวของเลือดผิดปกติ (Distributive shock) ซึ่งรวมถึงภาวะช็อกจากการติดเชื้อ [11]

การวินิจฉัยภาวะช็อกอาศัยเกณฑ์หลักสามประการ คือ (1) ความดันโลหิตเฉลี่ย (MAP) ต่ำกว่า 65 มิลลิเมตรปรอท ซึ่งเป็นจุดวิกฤตที่เพิ่มความเสี่ยงต่อภาวะไตวายเฉียบพลัน [1], (2) ความดันโลหิตตัวบน (SBP) ต่ำกว่า 90 มิลลิเมตรปรอท ซึ่งสัมพันธ์กับอัตราการเสียชีวิตสูงถึง

46% เทียบกับเพียง 5% ในกลุ่มที่มีค่า 90-109 มิลลิเมตรปรอท [3], และ (3) ดัชนีช็อกไดเอสโตลิก (DSI) มากกว่า 2.0 ซึ่งคำนวณจากอัตราการเต้นของหัวใจหารด้วยความดันโลหิตตัวล่าง และเป็นตัวทำนายการเสียชีวิตที่มีความแม่นยำ [8] การประเมินและวินิจฉัยภาวะช็อกอย่างรวดเร็วมีความสำคัญอย่างยิ่ง เนื่องจากภาวะช็อกที่ไม่ได้รับการวินิจฉัยและรักษาทันทั่วที่จะนำไปสู่การล้มเหลวของอวัยวะหลายระบบและเพิ่มความเสี่ยงต่อการเสียชีวิต

2.2 โครงข่ายประสาทแบบคอนโวลูชัน (Convolutional Neural Network; CNN)

โครงข่ายประสาทแบบคอนโวลูชัน (CNN) เป็นโครงข่ายประสาทเทียมที่ใช้ชั้น Convolution layer ในการสกัดคุณลักษณะสำคัญของข้อมูล โดยดั้งเดิมถูกออกแบบมาสำหรับข้อมูลภาพ 2 มิติ (2D CNN) แต่ได้ถูกพัฒนามาใช้กับข้อมูล 1 มิติ (1D CNN) เช่น ข้อมูลอนุกรมเวลา สัญญาณชีพต่าง ๆ ซึ่ง 1D CNN ทำงานโดยการสกัดคุณลักษณะสำคัญจากข้อมูลที่มีลักษณะเป็นลำดับ ช่วยให้สามารถเรียนรู้รูปแบบเฉพาะของข้อมูลได้อย่างมีประสิทธิภาพ ทำให้เหมาะกับการวิเคราะห์ข้อมูลทางการแพทย์ที่มีการเปลี่ยนแปลงตามเวลา แต่ก็สามารถใช้กับข้อมูลหนึ่งมิติเช่น เช่น สัญญาณชีพของผู้ป่วย [5]

2.3 หน่วยความจำระยะสั้นระยะยาว (Long Short-Term Memory; LSTM)

หน่วยความจำระยะสั้นระยะยาว (LSTM) เป็นประเภทของโครงข่ายประสาทแบบวนซ้ำที่พัฒนาขึ้นโดย Hochreiter และ Schmidhuber ในปี 1997 เพื่อแก้ไขข้อจำกัดของ RNN ดั้งเดิม โดยเฉพาะปัญหาการหายไปของเกรเดียนต์ (Vanishing Gradient) และค่าเกินขอบ (Exploding Gradient) ที่ทำให้ไม่สามารถเรียนรู้ความสัมพันธ์ในข้อมูลที่มีลำดับยาวได้ดี LSTM มีโครงสร้างพิเศษที่ประกอบด้วย 3 ประตูสำคัญ ได้แก่ Forget Gate ที่ตัดสินใจว่าควรลบข้อมูลใดออกจากหน่วยความจำ, Input Gate ที่ควบคุมการเพิ่มข้อมูลใหม่เข้าสู่หน่วยความจำ และ Output Gate ที่ควบคุมข้อมูลที่จะส่งออกไปเป็น Hidden State สำหรับขั้นตอนถัดไป ด้วยโครงสร้างนี้ทำให้ LSTM สามารถเลือกจำหรือลืมข้อมูลแต่ละส่วนได้ จึงสามารถจดจำความสัมพันธ์ระยะยาวได้ดีกว่า RNN ทั่วไป และมีประสิทธิภาพสูงสำหรับการวิเคราะห์ข้อมูลอนุกรมเวลา เช่น ข้อความเสียง หรือข้อมูลสัญญาณชีพทางการแพทย์ [4]

2.4 Transformer

Transformer เป็นสถาปัตยกรรมโครงข่ายประสาทเทียมที่พัฒนาโดย Vaswani และคณะในปี 2017 ซึ่งปฏิวัติวงการประมวลผลภาษาธรรมชาติและต่อมาได้ขยายไปสู่งานด้านอื่นๆ รวมถึงการวิเคราะห์ข้อมูลอนุกรมเวลา โดยจุดเด่นของ Transformer คือกลไก Self-Attention ที่สามารถพิจารณาความสัมพันธ์ระหว่างทุกๆ ส่วนของข้อมูลนำเข้าได้พร้อมกัน ไม่จำเป็นต้องประมวลผลข้อมูลตามลำดับเหมือน RNN หรือ LSTM ทำให้ Transformer สามารถจับความสัมพันธ์ระยะไกล (Long-range Dependencies) ได้ดี และประมวลผลแบบขนานได้ โครงสร้างของ Transformer ประกอบด้วยส่วนหลักๆ คือ Encoder และ Decoder โดย Encoder ทำหน้าที่เข้ารหัสข้อมูลนำเข้า

ผ่านกลไก Multi-Head Attention ที่สร้างการแทนค่า (Representations) ที่สมบูรณ์ด้วยบริบท ขณะที่ Decoder ทำหน้าที่ถอดรหัสเพื่อสร้างผลลัพธ์ นอกจากนี้ยังมีกลไก Positional Encoding ที่ช่วยให้ Transformer รักษาข้อมูลเกี่ยวกับลำดับของข้อมูลไว้ได้ ความสามารถในการจัดการกับข้อมูลที่ไม่ต่อเนื่องหรือมีช่องว่าง และการเรียนรู้ความสัมพันธ์ที่ซับซ้อนทำให้ Transformer เหมาะสมสำหรับการวิเคราะห์ข้อมูลทางการแพทย์ซึ่งมักมีรูปแบบที่ซับซ้อนและไม่สม่ำเสมอ [12][13]

3. ขั้นตอนการวิจัย

งานวิจัยนี้ ผู้วิจัยได้ใช้ข้อมูลทุติยภูมิจากระบบฐานข้อมูล Smart-ICU ของแผนกผู้ป่วยวิกฤต โรงพยาบาลศรีนครินทร์ จังหวัดขอนแก่น ตั้งแต่วันที่ 15 ตุลาคม 2565 – 3 กุมภาพันธ์ 2568 โดยคัดเลือกผู้ป่วยที่มีอายุมากกว่า 18 ปี และมีระยะเวลาอยู่ในแผนกผู้ป่วยวิกฤตไม่ต่ำกว่า 24 ชั่วโมง ซึ่งประกอบด้วยข้อมูลจำนวน 5 ชนิด ได้แก่ ข้อมูลผู้ป่วย ข้อมูลประวัติการรักษา ข้อมูลบันทึกสมดุลงานพยาบาล ข้อมูลผลตรวจทางห้องปฏิบัติการ และข้อมูลบันทึกสัญญาณชีพ รวมทั้งสิ้น 35 ตัวแปร ซึ่งรวบรวมเป็นข้อมูลคงที่ (Static features) และข้อมูลแบบพลวัต (Dynamic features) ที่จะเป็นข้อมูลรายชั่วโมง และรายนาที่ โดยมีจำนวนข้อมูลนำเข้าของผู้ป่วยในการทำนายภาวะช็อกล่วงหน้า 1, 2 และ 3 ชั่วโมง จำนวน 530, 527 และ 525 ราย ตามลำดับ ก่อนนำมาสร้างข้อมูลนำเข้าจำนวน 697, 698 และ 696 ข้อมูลนำเข้า ตามลำดับ ด้วยเทคนิค Sliding window ทำให้ได้ข้อมูลนำเข้าที่มีความสมดุลระหว่างคลาสในสัดส่วนที่เหมาะสม โดยมีขั้นตอนการเตรียมข้อมูลดังนี้

3.1 การเตรียมข้อมูล (Data Preparation)

1) รวมข้อมูลผู้ป่วย โดยการคัดเลือกตัวแปรโดยการปรึกษาแพทย์ถึงตัวแปรที่สำคัญกับภาวะช็อก และลบตัวแปรที่มีค่าสูญหายมากกว่า 70% ออกก่อนการรวมตาราง จากนั้นรวมข้อมูลทั้ง 5 ชนิดเข้าเป็นตารางเดียวโดยคัดกรองการเข้ามาในห้องผู้ป่วยวิกฤตครั้งแรกของผู้ป่วยแต่ละคนด้วย AdmissionID และรวมตารางด้วย AdmissionID, ICUDate และ ICUTime แบบ Left join โดยใช้ตารางบันทึกสัญญาณชีพเป็นตารางหลัก

2) จัดการค่าผิดปกติและค่านอกเกณฑ์ โดยกำจัดค่าผิดปกติโดยแทนค่าที่สูงหรือต่ำผิดปกติด้วยค่าสูญหาย และกำหนดช่วงค่าที่เป็นไปได้ในบางตัวแปร โดยอ้างอิงจากงานวิจัยที่เกี่ยวข้อง เช่น อัตราการเต้นของหัวใจ (HR) ที่ช่วง 30-260 ครั้ง/นาที อัตราการหายใจ (RR) 5-70 ครั้ง/นาที เป็นต้น [14]

3) จัดการค่าสูญหาย โดยในข้อมูลเชิงปริมาณแบบพลวัต จะใช้การเติมค่าที่สูญหายของข้อมูลอนุกรมเวลาด้วยวิธีการ Linear Interpolation สำหรับข้อมูลคงที่ ใช้เทคนิค MissForest

3.2 การระบุจุดที่เกิดภาวะช็อก

จะระบุจุดที่ผู้ป่วยมีภาวะช็อกเมื่อเข้าเงื่อนไขข้อใดข้อหนึ่งต่อไปนี้

1) MAP < 65 มิลลิเมตรปรอท


2) Systolic Blood Pressure < 90 มิลลิเมตรปรอท

3) Diastolic Shock Index > 2 ซึ่งคำนวณได้จากสัดส่วนระหว่าง Heart Rate และ Diastolic Blood Pressure

3.3 การเลือกช่วงข้อมูล สำหรับสร้างข้อมูลนำเข้า (Input)

เนื่องจากงานนี้ต้องการทำนายภาวะช็อกล่วงหน้า 3, 2, หรือ 1 ชั่วโมงโดยใช้ข้อมูล 24 ชั่วโมงก่อนหน้าของผู้ป่วย ผู้วิจัยจึงเตรียมข้อมูลดังนี้


จากภาพที่ 3.1 สำหรับผู้ป่วยที่มีภาวะช็อก จะได้ 1 ข้อมูลนำเข้า (input) ต่อเหตุการณ์ช็อก เนื่องจากข้อมูลที่ถูกเลือกมามีขนาด 1440 นาที (24 ชั่วโมง) โดยแต่ละข้อมูลนำเข้าจะใช้ข้อมูล 24 ชั่วโมงแรกว่าจะเกิดภาวะช็อกในอีก K ชั่วโมงข้างหน้าหรือไม่ จากภาพคือข้อมูลสีฟ้า นับเป็นหนึ่งข้อมูลนำเข้า



ภาพที่ 3.1 การสร้างข้อมูลนำเข้า และกำหนดค่า Label ข้อมูลผู้ป่วยที่มีภาวะช็อก

จากภาพที่ 3.2 สำหรับผู้ป่วยที่ไม่มีภาวะช็อก การสร้าง 24 ชั่วโมง ข้อมูลนำเข้าเริ่มนับจากจุดที่คนไข้เข้า ICU เนื่องจากอาการรุนแรงมักจะเกิดในช่วงแรก และเพื่อเพิ่มข้อมูลให้เกิดการสมดุลมากขึ้นผู้วิจัยทำการสร้าง Sliding windows โดยเก็บข้อมูลเพิ่มของคนไข้คนเดียวกันด้วยการสร้างข้อมูลนำเข้า 24 ชั่วโมงรวม 3 ข้อมูลนำเข้าด้วยการเลื่อนเวลาเพิ่ม 1 ชั่วโมง

ภาพที่ 3.2 การสร้างข้อมูลนำเข้า และกำหนดค่า Label ข้อมูลผู้ป่วยที่ไม่มีภาวะช็อก



3.3 การสร้างแบบจำลอง (Modeling)

1) การแบ่งข้อมูลด้วย วิธี Stratified Group 5-Fold Cross Validation

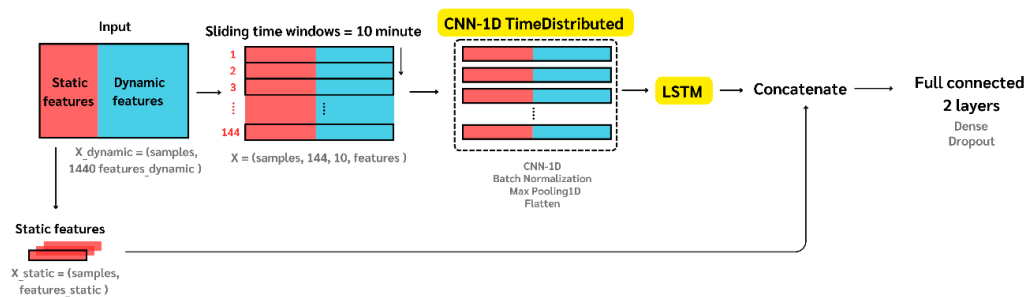
เนื่องจากผู้วิจัยสร้างหลายข้อมูลนำเข้าจากข้อมูล 1 Admission ของผู้ป่วย ผู้วิจัยได้ทำการแบ่งข้อมูลด้วย วิธี Stratified Group 5-Fold Cross Validation เพื่อรักษาสัดส่วนของคลาสเป้าหมาย (target class) ให้สมดุลระหว่างชุดข้อมูลฝึกและชุดข้อมูลตรวจสอบในแต่ละ fold และ

รักษาความเป็นกลุ่มของข้อมูลโดยจัดให้ข้อมูลทั้งหมดของผู้ป่วยแต่ละรายอยู่ในชุดเดียวกัน นั่นคือ ผู้ป่วย 1 ราย จะไม่ถูกแยกระหว่างชุดฝึกและชุดตรวจสอบ จากนั้นจะทำการทดสอบข้อมูลโดยใช้ข้อมูลที่แยกไว้อีกชุด เพื่อประเมินประสิทธิภาพของแบบจำลองกับข้อมูลไม่เคยพบ

2) โครงสร้างของแบบจำลอง

สำหรับงานวิจัยนี้ต้องการพัฒนาแบบจำลองการเรียนรู้เชิงลึกแบบอนุกรมเวลาเพื่อทำนายภาวะช็อกในแผนกผู้ป่วยวิกฤต ประกอบด้วยแบบจำลองแบบเดี่ยว ได้แก่ CNN, LSTM, Transformer และ แบบจำลองแบบผสมแก่ CNN+LSTM, CNN+Transformer และ LSTM+Transformer เนื่องจากงานวิจัยนี้ แบบจำลอง CNN+LSTM ซึ่งเป็นแบบจำลองแบบผสมให้ผลลัพธ์ที่ดีที่สุด โดยแบบจำลองนี้ มีโครงสร้างของแบบจำลอง ดังนี้

ภาพที่ 3.3 โครงสร้างแบบจำลอง CNN+LSTM



จากภาพที่ 3.3 ในการนำข้อมูลนำเข้า เข้าไปประมวลผลในแบบจำลอง ผู้วิจัยได้ทำการแยกข้อมูลคงที่ (Static features) ออกมาจากข้อมูลนำเข้าหลัก เพื่อต้องการเน้นย้ำหลังจากผ่านแบบจำลอง เพื่อในขั้นตอนก่อนการทำนาย ข้อมูลคงที่ จะไม่สูญเสียค่า หรือหายไปในขณะที่ประมวลผลผ่านแบบจำลอง โดยข้อมูลนำเข้าเหล่านี้จะถูกสร้าง Sliding Time windows 10 นาที เพื่อนำไปป้อนเข้าแบบจำลองแบบแจกแจงเวลา (Time distributed) ให้สกัดคุณลักษณะด้วย CNN-1D และส่งต่อไปยังชั้น LSTM ให้โมเดลเห็นลำดับของข้อมูลที่เข้ามาเพื่อสกัดคุณสมบัติตามลำดับเวลา แล้วนำ Output จากชั้นนี้ไปรวมกับ ข้อมูล Static ส่งไปยังชั้นเชื่อมโยงแบบสมบูรณ์เพื่อแสดงผลการทำนายด้วย sigmoid ฟังก์ชัน

สำหรับการประเมินแบบจำลองพิจารณา ด้วยกราฟ AUC-ROC ใช้เพื่อประเมินความสามารถของแบบจำลองโดยแสดงความสัมพันธ์ระหว่าง True Positive Rate (Sensitivity) และ False Positive Rate (1 - Specificity) โดย ค่า AUC ที่เข้าใกล้ 1 บ่งบอกว่าแบบจำลองมีความแม่นยำสูงในการแยกแยะระหว่างกลุ่มเป้าหมาย และ AUC-PR (Area Under the Precision-Recall Curve) ใช้ประเมินประสิทธิภาพของแบบจำลองในกรณีที่ข้อมูลมีความไม่สมดุลระหว่างคลาส

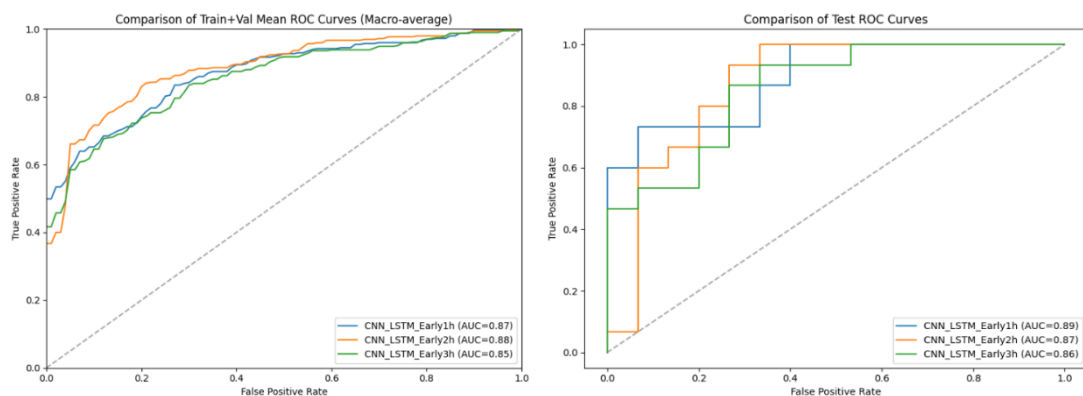
4. ผลการวิจัย

4.1 ผลการเปรียบเทียบประสิทธิภาพแบบจำลอง

ตารางที่ 4.1 ผลการเปรียบเทียบประสิทธิภาพแบบจำลองในช่วงการทำนายล่วงหน้าต่างๆ สำหรับข้อมูลทดสอบ

แบบจำลอง	ช่วงเวลาการทำนายล่วงหน้า (ชั่วโมง)					
	1		2		3	
	AUC	AUC-PR	AUC	AUC-PR	AUC	AUC-PR
CNN	0.85	0.84	0.84	0.85	0.84	0.80
LSTM	0.79	0.73	0.86	0.79	0.84	0.74
Transformer	0.76	0.82	0.68	0.77	0.84	0.83
CNN+LSTM	0.89	0.91	0.87	0.80	0.86	0.87
CNN+Transformer	0.88	0.87	0.79	0.75	0.75	0.68
LSTM+Transformer	0.80	0.76	0.82	0.78	0.84	0.82

จากตารางที่ 4.1 แสดงให้เห็นว่าแบบจำลอง CNN+LSTM ให้ประสิทธิภาพดีที่สุดโดยรวมของทุกช่วงเวลาการทำนายล่วงหน้า โดยมีค่า AUC-ROC และ AUC-PR สูงที่สุดในช่วงการทำนายล่วงหน้า 1 ชั่วโมง (AUC-ROC = 0.89, AUC-PR = 0.91) และยังคงรักษาประสิทธิภาพที่ดีในช่วงเวลาทำนายล่วงหน้าที่ 2 และ 3 ชั่วโมง รองลงมาคือแบบจำลอง CNN เดี่ยว ซึ่งให้ผลลัพธ์ที่ค่อนข้างสม่ำเสมอในทุกช่วงเวลา โดยเฉพาะในช่วงการทำนาย 2 ชั่วโมงล่วงหน้าที่มีค่า PR สูงถึง 0.85 และแบบจำลอง LSTM ที่มีประสิทธิภาพดีในช่วงการทำนายล่วงหน้า 2 ชั่วโมง (AUC-ROC = 0.86) ซึ่งแบบจำลองแบบผสมช่วยปรับปรุงประสิทธิภาพโดยรวม โดย CNN+LSTM ให้ผลลัพธ์ที่ดีที่สุด ในขณะที่การรวม CNN+Transformer หรือ LSTM+Transformer ไม่ได้แสดงการปรับปรุงที่มีนัยสำคัญเมื่อเทียบกับแบบจำลองพื้นฐาน




ภาพที่ 4.1 ROC-Curve ประสิทธิภาพแบบจำลอง CNN+LSTM ในแต่ละช่วงการทำนายล่วงหน้า

เมื่อวิเคราะห์ประสิทธิภาพของแบบจำลอง CNN+LSTM ในแต่ละช่วงเวลาการทำนายพบว่า การทำนายล่วงหน้า 1 ชั่วโมงให้ประสิทธิภาพโดยรวมดีที่สุด โดยเฉพาะค่า AUC-ROC ในชุดทดสอบที่ 0.89 ซึ่งสูงกว่าช่วงเวลาอื่น เนื่องจากข้อมูลที่ใกล้กับเหตุการณ์มากกว่ามีความสัมพันธ์และสามารถบ่งชี้การเกิดภาวะช็อกได้แม่นยำกว่า โดยค่า AUC-PR ในช่วงการทำนายล่วงหน้า 1 ชั่วโมงยังสูงถึง 0.91 แสดงถึงความสามารถของแบบจำลองในการระบุผู้ป่วยที่มีความเสี่ยงได้อย่างถูกต้องและลดการแจ้ง

เดือนที่ผิดพลาด เมื่อระยะเวลาการทำนายเพิ่มขึ้นเป็น 2 ชั่วโมงและ 3 ชั่วโมง ประสิทธิภาพของแบบจำลองลดลงตามลำดับ ซึ่งสะท้อนถึงความท้าทายในการทำนายเหตุการณ์ล่วงหน้าที่ไม่ไกลออกไป เนื่องจากข้อมูลทางสรีรวิทยาอาจมีการเปลี่ยนแปลงได้อย่างรวดเร็วในผู้ป่วยวิกฤต

อย่างไรก็ตาม แม้ว่าประสิทธิภาพจะลดลงเล็กน้อยในการทำนายล่วงหน้า 3 ชั่วโมง แต่ค่า AUC-PR ที่ 0.87 ซึ่งยังคงมีค่าสูง แสดงว่าแบบจำลองยังคงมีความแม่นยำในการระบุผู้ป่วยที่มีความเสี่ยงแม้ในช่วงเวลาที่ไกลออกไป

4.2 การทำความเข้าใจแบบจำลองด้วย SHAP

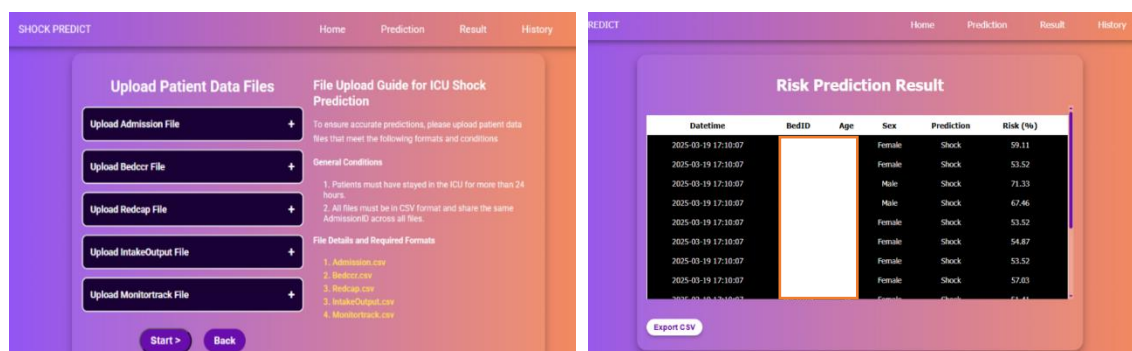


ภาพที่ 4.2 อิทธิพลของตัวแปรคงที่ที่มีผลต่อการทำนายภาวะช็อก

จากภาพที่ 4.2 กราฟ SHAP จะเห็นได้ว่าคุณลักษณะที่มีอิทธิพลต่อโมเดล เช่น SAP-II ที่มีค่าสูงส่งผลเชิงบวกต่อการทำนาย ในขณะที่ค่าต่ำจะส่งผลทางด้านลบแทน

4.3 ตัวอย่างการนำแบบจำลองไปใช้งาน

จากภาพที่ 4.3 คือตัวอย่างเว็บแอปพลิเคชันในการทำนายภาวะช็อกโดยภาพซ้ายคือหน้าต่างนำเข้าข้อมูลผู้ป่วย และภาพทางขวาคือภาพหน้าต่างผลการทำนายของแบบจำลอง



ภาพที่ 4.3 หน้าต่างเว็บแอปพลิเคชันทำนายภาวะช็อกของผู้ป่วย

5. สรุปผล

5.1 อภิปรายผลการวิจัย

ผลการวิจัยพบว่าแบบจำลอง CNN+LSTM มีประสิทธิภาพดีที่สุดในการทำนายการเกิดภาวะช็อกล่วงหน้าในทุกช่วงเวลา ทั้ง 1, 2 และ 3 ชั่วโมง สำหรับการต่อยอด ควรมีการพัฒนาแบบจำลองให้สามารถประมวลผลข้อมูลและทำนายความเสี่ยงแบบเรียลไทม์ ด้วยการปรับปรุงประสิทธิภาพของอัลกอริทึม และออกแบบระบบที่สามารถดึงข้อมูลจากเครื่องติดตามสัญญาณชีพและประมวลผลอัตโนมัติ นอกจากนี้อาจทำการ Pre-training จากข้อมูลสาธารณสุขขนาดใหญ่ เช่น MIMIC-IV, eICU หรือ PhysioNet เพื่อทำการ Pre-training แบบจำลองก่อน Fine-tune ด้วยข้อมูลเฉพาะของโรงพยาบาล

6. เอกสารอ้างอิง

- [1] P. Asfar, F. Meziani, J. F. Hamel, F. Grelon, B. Megarbane, N. Anguel, J. P. Mira, P. F. Dequin, S. Gergaud, N. Weiss, F. Legay, Y. Le Tulzo, M. Conrad, R. Robert, F. Gonzalez, C. Guitton, F. Tamion, J. M. Tonnelier, P. Guezennec, T. Van Der Linden, et al., "High versus low blood-pressure target in patients with septic shock," *The New England Journal of Medicine*, vol. 370, no. 17, pp. 1583–1593, 2014. Available: <https://doi.org/10.1056/NEJMoa1312173>
- [2] H. F. Deng, M. W. Sun, Y. Wang, J. Zeng, T. Yuan, T. Li, D. H. Li, W. Chen, P. Zhou, Q. Wang, and H. Jiang, "Evaluating machine learning models for sepsis prediction: A systematic review of methodologies," *iScience*, vol. 25, no. 1, 2022, 103651. Available: <https://doi.org/10.1016/j.isci.2021.103651>
- [3] D. A. Edelman, M. T. White, J. G. Tyburski, and R. F. Wilson, "Post-traumatic hypotension," *Shock*, vol. 27, no. 2, pp. 134–138, 2007. Available: <https://doi.org/10.1097/01.shk.0000239772.18151.18>
- [4] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997. Available: <https://doi.org/10.1162/neco.1997.9.8.1735>
- [5] S. Kiranyaz, O. Avci, O. Abdeljaber, T. Ince, M. Gabbouj, and D. J. Inman, "1D convolutional neural networks and applications: A survey," *Mechanical Systems and Signal Processing*, vol. 151, 2021, 107398. Available: <https://doi.org/10.1016/j.ymssp.2020.107398>
- [6] C. Lin, Y. Zhang, J. Ivy, M. Capan, R. Arnold, J. M. Huddleston, and M. Chi, "Early diagnosis and prediction of sepsis shock by combining static and dynamic information using Convolutional-LSTM," *Proceedings of the 2018 IEEE International Conference on Healthcare Informatics (ICHI)*, 2018, pp. 219–228. DOI: 10.1109/ICHI.2018.00032
- [7] A. Kumar, D. Roberts, K. E. Wood, B. Light, J. E. Parrillo, S. Sharma, R. Suppes, D. Feinstein,

-
- S. Zanotti, L. Taiberg, D. Gurka, A. Kumar, and M. Cheang, "*Duration of hypotension before initiation of effective antimicrobial therapy is the critical determinant of survival in human septic shock*," *Critical Care Medicine*, vol. 34, no. 6, pp. 1589–1596, 2006. Available: <https://doi.org/10.1097/01.ccm.0000217961.75225.e9>
- [8] G. A. Ospina-Tascón, J. L. Teboul, G. Hernandez, I. Alvarez, A. I. Sánchez-Ortiz, L. E. Calderón-Tapia, R. Manzano-Nunez, E. Quiñones, H. J. Madriñan-Navia, J. E. Ruiz, J. L. Aldana, and J. Bakker, "*Diastolic shock index and clinical outcomes in patients with septic shock*," *Annals of Intensive Care*, vol. 10, no. 1, 2020, 41. Available: <https://doi.org/10.1186/s13613-020-00658-8>
- [9] Y. Sakr, U. Jaschinski, X. Wittebole, T. Szakmany, J. Lipman, S. A. Namendys-Silva, I. Martin-Loeches, M. Leone, M. N. Lupu, J. L. Vincent, and ICON Investigators, "*Sepsis in intensive care unit patients: Worldwide data from the intensive care over nations audit*," *Open Forum Infectious Diseases*, vol. 5, no. 12, 2018, ofy313. Available: <https://doi.org/10.1093/ofid/ofy313>
- [10] Y. Tang, Y. Zhang, and J. Li, "*A time series driven model for early sepsis prediction based on transformer module*," *BMC Medical Research Methodology*, vol. 24, no. 1, 2024. Available: <https://doi.org/10.1186/s12874-023-02138-6>
- [11] J. L. Vincent and D. De Backer, "*Circulatory shock*," *The New England Journal of Medicine*, vol. 369, no. 18, pp. 1726–1734, 2013. Available: <https://doi.org/10.1056/NEJMra1208943>
- [12] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "*Attention is all you need*," *arXiv preprint*, arXiv:1706.03762, 2017. Available: <https://arxiv.org/abs/1706.03762>
- [13] Q. Wen, T. Zhou, C. Zhang, W. Chen, Z. Ma, J. Yan, and L. Sun, "*Transformers in time series: A survey*," *arXiv preprint*, arXiv:2202.07125, 2023. Available: <https://doi.org/10.48550/arXiv.2202.07125>
- [14] R. Luo, M. Gong, and C. Li, "*PT3: A Transformer-based Model for Sepsis Death Risk Prediction via Vital Signs Time Series*," *Proceedings of the 2023 International Joint Conference on Neural Networks (IJCNN)*, 2023, pp. 1–8.